

DÖNEM PROJESİ • 2025-2026 BAHAR

Online Retail II

Müşteri Yaşam Boyu Değeri (CLV) Tahmin Sistemi

Apache Kafka • Spark • Delta Lake • MLflow • Streamlit

Tuna Kömür

Büyük Veri Analizine Giriş
Bilgisayar Mühendisliği

Mayıs 2026

Problem Tanımı

Customer Lifetime Value (CLV) — Regresyon Problemi

TEKNİK PROBLEM

Müşterilerin geçmiş davranışlarına dayanarak gelecekteki harcamalarını tahmin et

Tip: Denetimli öğrenme — Regresyon

Hedef (Y): Sonraki 6 ayda toplam harcama (£)

Girdiler (X): 10 davranışsal feature

İŞ DEĞERİ

Neden CLV Tahmini Önemli?

- Pazarlama bütçesi optimizasyonu
- Müşteri segmentasyonu
- Kişiselleştirilmiş kampanyalar
- Müşteri sadakat stratejileri
- Churn (kayıp) öngörüsü

Geçmiş 18 ay → **Gelecek 6 ay**

Feature türetimi → Tahmin

Veri Seti

Online Retail II — UCI Machine Learning Repository

1.07M

İşlem Sayısı

2 yıl

Tarih Aralığı

43.5 MB

Veri Boyutu

8

Sütun

VERİ SETİ DETAYLARI

Kaynak: UCI Machine Learning Repository

Dönem: Aralık 2009 – Aralık 2011


Format: Excel (.xlsx)

Sütunlar:

InvoiceNo, StockCode, Description,
Quantity, InvoiceDate, UnitPrice,
CustomerID, Country

Sistem Mimarisi

Uçtan uca veri akışı — 8 servis, hybrid (Docker + Host)



SERVİS KONUMU VE PORT YAPILANDIRMASI

Servis	Konum	Port	Görev
Kafka + Zookeeper	Docker	9092 / 2181	Mesaj kuyruğu
Kafka UI	Docker	8080	Yönetim arayüzü
MLflow	Docker	5001	Deney takibi
Spark + Jupyter	Host (ARM64)	4040 / 8888	İşleme + geliştirme
Streamlit	Host	8501	Dashboard

Streaming Pipeline

Faz 3-4: Kafka Producer ve Spark Structured Streaming

KAFKA PRODUCER

Veri Akış Simülasyonu

- 100.000 mesaj akıtıldı (örneklem)
- Excel → JSON dönüşümü
- Required fields: timestamp, kullanıcı_ID, olay_tipi, ilgili_ID
- 3 partition Kafka topic
- Docker container'da çalışıyor

500 msg/s

Throughput hızı
(Producer rate)

SPARK STRUCTURED STREAMING

Bronze → Silver Medallion

- Kafka'dan structured streaming okuma
- Delta Lake'e yazma (ACID compliant)
- Exactly-once semantics (checkpoint)
- Silver'da temizlik:
purchase / cancellation ayrımı
null kontrolü, tip dönüşümleri

100%

Silver'da doluluk
(null değer yok)

EDA Bulguları

Silver tablosundaki paternler — 8 görsel analiz

1

Coğrafi Yoğunluk

%90+

İşlemlerin büyük çoğunluğu Birleşik Krallık'tan. Diğer Avrupa ülkeleri marjinal pay alıyor.

2

Saatlik Patern

10–15

saat aralığı

Peak alışveriş saatleri öğle çevresinde. Sabah erken ve akşam geç çok daha az yoğun.

3

Mevsimsellik

Kas-Ara

Yılın peak'i kasım-aralıkta (Black Friday + Christmas). Yaz aylarında dip seviye.

4

Müşteri Dağılımı

Çarpık

sağa eğimli

Median << Mean. Birkaç mega müşteri toplam harcamanın büyük kısmını oluşturuyor.

Feature Engineering

Müşteri seviyesinde 10 davranışsal feature → Gold tablosu

RFM ÇEKİRDEK

40+ yıllık e-ticaret modellemesi

recency_days

Son alışverişten gün

frequency

Toplam fatura sayısı

monetary

Toplam harcama (£)

DAVRANIŞSAL

Müşteri alışveriş paterni

avg_basket_value

Sepet ortalaması

avg_days_between

Alışverişler arası gün

unique_products

Ürün çeşitliliği

cancellation_count

Geçmiş iptaller

active_months

Aktif ay sayısı

most_active_hour

Yoğun alışveriş saati

COĞRAFI

Kategorik sinyal

country

Müşterinin ülkesi



TARGET: future_spending — Tahmin döneminde toplam harcama (regresyon hedefi)

Model Karşılaştırması

5 regresyon modeli — RMSE, MAE, R^2 metrikleri

PERFORMANS METRİKLERİ

Model	RMSE	MAE	R^2
LinearRegression ★	1596	677	0.66
GeneralizedLinearRegression	1596	677	0.66
DecisionTree	1855	743	0.54
RandomForest	2267	855	0.31
GradientBoostedTrees	3251	1184	-0.42

★ Linear Regression küçük dataset'te en iyi performansı gösterdi



EN İYİ MODEL

Linear Regression

0.66

R^2 SCORE

Varyansın %66'sını açıklıyor



NEDEN?

Küçük dataset'te basit doğrusal modeller, ensemble'lardan (RF, GBT) daha iyi genelleme yapar.

MLflow ile Deney Takibi

Tüm modeller, parametreler ve metrikler tek merkezde

KAYDEDİLENLER

Her Run İçin Tam İzlenebilirlik

- ✓ **Parametreler**
maxIter, regParam, maxDepth, numTrees, ...
- ✓ **Metrikler**
RMSE, MAE, R², training_time_seconds
- ✓ **Model Artifact'i**
Eğitilmiş model — yeniden yüklenebilir
- ✓ **Tag'ler**
model_type, deney etiketi
- ✓ **Zaman damgası**
Run history ve karşılaştırma

6

Toplam Run

5 model + 1 feature importance summary

Experiment:

customer_lifetime_value_prediction



MLFLOW NE SAĞLADI?

Reprodüksiyon: Her deney bire bir tekrar edilebilir

Karşılaştırma: Modeller yan yana metric'lerle görülebilir

Versiyonlama: Aynı modelin farklı parametre denemeleri

Paylaşılabilirlik: UI'da takım üyelerine sonuçlar gösterilebilir

Streamlit Dashboard

İnteraktif web arayüzü — 4 sayfa + Plotly görselleri



EDA

- Aylık trend
- Saatlik dağılım
- Coğrafi analiz
- Top ürünler



Customer Analysis

- RFM görselleri
- Top 10 müşteri
- Segmentasyon
- Aktivite paterni



Model Comparison

- 5 model karşılaştırma
- Grouped bar chart
- MLflow entegrasyonu
- Detaylı tablo



Predictions

- Feature importance
- Scatter plot
- Residual analizi
- İnteraktif tahmin

ERİŞİM: `streamlit run dashboard/app.py` → <http://localhost:8501>

Teknoloji Stack: Streamlit (UI) + Plotly (görseller) + Pandas (veri) + Spark (Delta okuma)

Karşılaşılan Zorluklar

Pipeline süresince çözülen kritik sorunlar

01

Spark + Apple Silicon

Problem: Docker amd64 emülasyonu Spark Session'da donmalar yaratıyordu

Çözüm: Host'ta native ARM64 olarak çalıştırma

✓ *15x hız iyileşmesi*

02

MLflow Read-Only Filesystem

Problem: Model artifact'leri /mlflow-artifacts'a kaydedilemiyordu

Çözüm: Artifact path'i /mlruns/artifacts'a taşıma + volume rw

✓ *Tüm modeller log'lanabildi*

03

setuptools 81 Kırılması

Problem: pkg_resources modülü kaldırıldı, MLflow bağımlıydı

Çözüm: setuptools<81 sürüm pin'i

✓ *Sorunsuz import*

04

Model R² Felaketi

Problem: İlk eğitim R² = -115000 — outlier'lar bozuyordu

Çözüm: %99 quantile outlier temizliği

✓ *R² 0.66'ya çıktı*

Sonuç

Uçtan uca production-grade büyük veri pipeline'ı

13+

Git Commit

5

ML Model

0.66

En İyi R^2

4

Dashboard Sayfası

✓ BAŞARILAN HEDEFLER

- Uçtan uca production pipeline kuruldu
- Medallion mimarisi uygulandı
- 5 model MLflow ile eğitildi
- İnteraktif dashboard oluşturuldu
- Modüler ve yeniden kullanılabilir



GELECEK ÇALIŞMALAR

- Tam dataset (1M+ işlem) ile eğitim
- Hyperparameter tuning (GridSearch)
- Daha fazla feature (mevsimsellik, web log)
- Real-time prediction REST API
- A/B testing ile iş etkisi ölçümü

GitHub: github.com/TunaKomur/big-data-online-retail-pipeline

Teşekkürler — Sorular?